ALEJANDRO DAVID LARCO TENELEMA

Desarrollador de Software | Python · RAG · IA Aplicada

Quito, Ecuador · +593 98 492 2541 · alejandrolarco2020@hotmail.com

LinkedIn · GitHub · Portafolio con casos de estudio

PERFIL PROFESIONAL

Desarrollador de software (egresado 2026) enfocado en integrar modelos de lenguaje (LLMs) y optimizar recursos. Diseñé un asistente con arquitectura híbrida local/nube y memoria vectorial (RAG) que redujo su tiempo de primera respuesta de 9,13 s a 0,47 s (−94%) en una GPU de 6 GB. Busco mi primer puesto en un equipo que desarrolle productos con LLMs.

PROYECTOS DESTACADOS

L-IA — Asistente de inteligencia artificial con memoria propia Proyecto personal · 2 documentos técnicos (38 páginas)

Python · FastAPI · Go · ChromaDB · Ollama · Gemini API · Tauri · React

- Diseñé un enrutador de consultas ("Semáforo v3") que elige entre Gemma 2 local y Gemini en la nube según la intención, la presencia de código y los tokens estimados.
- Implementé memoria RAG local (ChromaDB, embeddings en CPU, filtro por distancia semántica) y obligué al modelo a citar el documento de origen.
- Reduje el tiempo hasta el primer token (TTFT) de 9,13 s a 0,47 s (−94%) con FastAPI asíncrono y streaming SSE, y estabilicé Gemma 2 en 12,5–14 tokens/s en una GPU de 6 GB.
- Diseñé una ingesta dual (memoria vectorial y espacio de trabajo activo) y una arquitectura multi-sesión en SQLite con historial y archivos aislados por pestaña.
- Construí un flujo agéntico con tool calling (el modelo decide cuándo invocar herramientas, como buscar archivos), con tres niveles de riesgo, confirmación humana en acciones destructivas y un Kill Switch que libera la GPU.
- Extraje tareas bloqueantes a microservicios locales en Go (REST, goroutines): búsqueda paralela de archivos, telemetría y lectura de Git, para que Python no compita con la inferencia por CPU y RAM.
- Migré la interfaz de Tkinter a Tauri + React (0 MB de VRAM) e implementé voz local con Vosk, faster-whisper y Edge-TTS.

  Ver caso de estudio

Sistema de gestión y tienda en línea — Taller Arte Titi_Val Proyecto de integración curricular

Laravel · PHP · MySQL · JavaScript · Bootstrap

- Desarrollé un sistema full-stack de 9 módulos (Laravel 13, MySQL) con acceso por roles y transacciones ACID para un taller artesanal. Documenté más de 40 decisiones técnicas en 52 páginas.

  Ver caso de estudio

Demo de videojuego: enemigos con IA, físicas y armas Proyecto personal · 23 páginas de documentación

C++ · Unreal Engine 5 · Behavior Trees · Chaos Physics

- Configuré Behavior Trees y percepción sensorial (visión y audición) para enemigos con una arquitectura híbrida C++/Blueprint en Unreal Engine 5, orientada a comportamientos tácticos de combate.

  Ver caso de estudio

HABILIDADES

IA y RAG: Python 3.11, RAG, Agentic Workflows (tool calling), Prompt Engineering, ChromaDB, Ollama (Gemma 2), Gemini API, embeddings (all-MiniLM-L6-v2), Faster-Whisper, Vosk, Edge-TTS

Backend y datos: FastAPI, Go (microservicios REST), Server-Sent Events (SSE), SQLite, SQL, MySQL, PHP 8 / Laravel

Interfaz de escritorio: React, Tauri, JavaScript (ES6+), Vite

Otros: C++ (Unreal Engine 5, Behavior Trees), Git, GitHub

Idiomas: Español (nativo) · Inglés nivel A2 (certificado por el Instituto Sucre): lectura de documentación técnica, expresión oral en mejora

EXPERIENCIA LABORAL

Pasante de TICs | Hospital Gineco Obstétrico Nueva Aurora Feb 2025 – Abr 2025 · Quito

- Brindé soporte técnico preventivo y correctivo de hardware, software y sistemas operativos en un entorno hospitalario donde el servicio no puede detenerse.
- Diagnostiqué fallas de red local (LAN) y configuré equipos y periféricos bajo esquemas de atención prioritaria.

EDUCACIÓN

Tecnología Superior en Desarrollo de Software | Instituto Superior Universitario Sucre Egresado 2026

Malla y titulación culminadas

Bachiller en Ciencias | Unidad Educativa Fiscal "Quito Sur" 2019 – 2022